

Description du projet

Contexte

Les maladies cardiovasculaires sont la première cause de mortalité dans le monde. Une large part des facteurs de risque est **connue et mesurable** : hypertension, cholestérol, diabète, tabagisme, sédentarité, surpoids. Identifier les profils les plus exposés à partir de données déclaratives est un enjeu majeur de santé publique, notamment pour cibler les actions de prévention.

Ce projet exploite les données du **Behavioral Risk Factor Surveillance System** (BRFSS), la grande enquête de santé annuelle des **Centers for Disease Control and Prevention** (CDC) aux États-Unis, dans son édition 2015.

Objectif

Construire une **chaîne analytique complète**, de la donnée brute jusqu'à une application web déployée, autour d'une question centrale :

À partir du profil de santé déclaré d'une personne, peut-on estimer son risque de maladie ou d'accident cardiaque, et identifier les facteurs les plus déterminants ?

Le projet ne se limite pas à un modèle prédictif : il couvre toute la chaîne de valeur de la donnée — extraction, entreposage, restitution décisionnelle, exploration, modélisation et mise en production.

Nature du projet

Il s'agit d'un **projet personnel de data analytics et de machine learning**, conçu comme une pièce de portfolio. Les données étant **publiques** (CDC / Kaggle), leur source est citée ouvertement et le jeu de données est versionné dans le dépôt pour garantir la reproductibilité.

Périmètre : une chaîne en huit modules

Module	Rôle
ETL & EDA	Extraction, nettoyage, contrôles qualité, analyse exploratoire
Entrepôt de données	Schéma en étoile sous DuckDB
Power BI	Rapport décisionnel branché sur l'entrepôt
Machine Learning	Comparaison de modèles, sélection, interprétation
Data Mining	Exploration non supervisée (ACP, clustering, t-SNE)
Application web	Interface de prédiction déployée
Rapport	Documentations techniques et rapport final
Présentation	Support de restitution

Stack technique

- **Langage** : Python (pandas, scikit-learn, XGBoost)
- **Entrepôt** : DuckDB (sans serveur, un fichier = une base)
- **Décisionnel** : Power BI Desktop, connecté en ODBC direct
- **Interprétabilité** : SHAP
- **Application** : Streamlit
- **Rapports** : génération PDF par script (fpdf2)

Livrables attendus

1. Un dépôt GitHub public, documenté et reproductible. 2. Un rapport décisionnel Power BI. 3. Des modèles de machine learning comparés et un modèle retenu. 4. Une application web de prédiction déployée (URL publique). 5. Un rapport final PDF et un support de présentation.

Limite méthodologique fondamentale

Les variables explicatives sont **auto-déclarées au même moment** que la variable cible, lors d'un unique entretien. Les relations mises en évidence sont donc des **associations transversales** : elles ne permettent d'établir ni causalité, ni prédiction d'un événement futur. Le modèle estime un risque à partir d'un profil, il ne prédit pas la survenue d'un accident cardiaque. Cette limite est rappelée dans tous les livrables du projet.