

Description des données

Source

- **Jeu de données** : *Heart Disease Health Indicators Dataset* (Kaggle)
- **Origine primaire** : CDC — *Behavioral Risk Factor Surveillance System* (BRFSS), édition 2015

- **Nature** : enquête téléphonique de santé menée à l'échelle des États-Unis
- **Licence** : données publiques

Le fichier utilisé est une version déjà **nettoyée et encodée** du BRFSS 2015, diffusée sur Kaggle. Les non-réponses ont été écartées en amont par l'auteur du jeu.

Volumétrie

Propriété	Valeur
Nombre de répondants	253 680
Nombre de variables	22
Type	Entièrement numérique
Valeurs manquantes	Aucune
Doublons exacts	23 899 (conservés — voir plus bas)

La variable cible

HeartDiseaseorAttack — indique si le répondant a déclaré une maladie coronarienne ou un infarctus (0 = non, 1 = oui).

- **Prévalence** : 9,42 % de cas positifs
- **Conséquence** : classes fortement déséquilibrées. Un modèle prédisant « aucun malade » atteindrait 90,58 % d'exactitude tout en étant inutile — l'exactitude est donc écartée comme critère au profit du ROC-AUC, du PR-AUC, du rappel et du F1.

Les 22 variables

Conditions médicales déclarées

Variable	Description	Modalités
HighBP	Hypertension artérielle	0 / 1
HighChol	Cholestérol élevé	0 / 1
CholCheck	Dosage du cholestérol depuis 5 ans	0 / 1
Stroke	Antécédent d'AVC	0 / 1
Diabetes	Statut diabétique	0 / 1 / 2
DiffWalk	Difficulté sérieuse à marcher	0 / 1

Comportements et hygiène de vie

Variable	Description	Modalités
Smoker	A fumé au moins 100 cigarettes dans sa vie	0 / 1
PhysActivity	Activité physique le mois écoulé	0 / 1
Fruits	Fruits au moins une fois par jour	0 / 1
Veggies	Légumes au moins une fois par jour	0 / 1
HvyAlcoholConsump	Consommation d'alcool excessive	0 / 1

État de santé perçu et mesures

Variable	Description	Modalités
GenHlth	État de santé général perçu	1 (excellent) à 5 (mauvais)
MentHlth	Jours de mal-être mental sur 30	0 à 30
PhysHlth	Jours de mal-être physique sur 30	0 à 30
BMI	Indice de masse corporelle	12 à 98

Accès aux soins et données socio-démographiques

Variable	Description	Modalités
AnyHealthcare	Dispose d'une couverture santé	0 / 1
NoDocbcCost	A renoncé à un médecin pour raison financière	0 / 1
Sex	Sexe déclaré	0 (femme) / 1 (homme)
Age	Tranche d'âge	1 à 13
Education	Niveau d'études	1 à 6
Income	Tranche de revenu du foyer	1 à 8

Codebook des variables ordinales

Les variables **Age**, **Education** et **Income** sont codées par des entiers dont voici la signification (source : codebook BRFSS 2015). Ces libellés sont réintégrés dans l'entrepôt pour afficher un texte lisible plutôt qu'un code.

Tranches d'âge (Age)

Code	Tranche	Code	Tranche
1	18-24 ans	8	55-59 ans
2	25-29 ans	9	60-64 ans
3	30-34 ans	10	65-69 ans
4	35-39 ans	11	70-74 ans
5	40-44 ans	12	75-79 ans
6	45-49 ans	13	80 ans et plus
7	50-54 ans		

Niveau d'études (Education)

Code	Niveau
1	Aucune scolarité
2	Primaire
3	Secondaire non achevé
4	Secondaire achevé
5	Supérieur non achevé
6	Diplômé du supérieur

Tranche de revenu du foyer (Income)

Code	Revenu annuel
1	Moins de 10 000 \$
2	10 000 à 15 000 \$
3	15 000 à 20 000 \$
4	20 000 à 25 000 \$
5	25 000 à 35 000 \$
6	35 000 à 50 000 \$
7	50 000 à 75 000 \$
8	75 000 \$ et plus

Qualité des données

Aucune valeur manquante

Le fichier ne contient aucune valeur manquante — conséquence du nettoyage préalable appliqué sur Kaggle. Aucune stratégie d'imputation n'est donc nécessaire, mais cette sélection en amont a pu écarter des profils particuliers (les personnes les plus fragiles répondant généralement moins).

Doublons exacts : conservés

Le jeu contient 23 899 lignes strictement identiques à une autre (9,42 %). Une analyse en quatre tests (détaillée dans la documentation ETL & EDA) montre qu'il s'agit de **collisions légitimes** entre répondants distincts, et non d'erreurs de saisie : avec 22 variables grossièrement codées, deux personnes différentes peuvent présenter le même profil. Les supprimer ferait passer artificiellement la prévalence de 9,42 % à 10,32 %. Ils sont donc **conservés**.

Valeurs extrêmes : signalées, non supprimées

Aucune valeur n'est supprimée ni corrigée dans le pipeline. Les anomalies (IMC physiologiquement improbable, incohérences) sont signalées par des drapeaux booléens, laissant la table analytique fidèle à la source.