

Documentation technique

Data Mining

BRFSS Heart Analytics

Exploration non supervisée : ACP, clustering,
et découverte de profils de population
(BRFSS, CDC, 2015)

Ahmed Ben Arfa

21/07/2026

github.com/AhmedBenArfa/BRFSS-Heart-Analytics

1. Objectif et démarche

Cette phase explore les données par apprentissage non supervisé. Contrairement à l'analyse exploratoire, qui décrivait les variables une à une, le data mining cherche des structures d'ensemble : des groupes de répondants aux profils semblables.


Principe : ne pas utiliser la cible

Le regroupement s'effectue sur les 21 variables de santé, sans la variable maladie. Les groupes émergent donc des seuls profils de population ; leur taux de maladie n'est mesuré qu'ensuite. Un groupe qui se révèle très exposé sans qu'on ait utilisé la cible pour le construire est une découverte solide, non un artefact.

Trois techniques complémentaires sont mobilisées : l'ACP (réduction de dimension et visualisation), le clustering (k-means et classification ascendante hiérarchique), et le t-SNE (projection 2D non linéaire). Toutes reposant sur des distances, les variables sont préalablement centrées et réduites.

2. Analyse en composantes principales


L'ACP recherche les directions de plus grande variance pour résumer les 21 variables par quelques axes.



Éboulis des valeurs propres et variance cumulée

Une compression faible, et c'est une information


La première composante ne capte que $\sim 17\%$ de la variance, et il faut 14 composantes pour atteindre 80 %. L'ACP compresses donc mal ces données : il n'existe pas deux ou trois axes dominants. La cause est la nature des variables — majoritairement binaires et peu corrélées entre elles. La structure est intrinsèquement multidimensionnelle : chaque variable apporte une information propre. L'ACP servira à visualiser et interpréter, pas à réduire.



Cercle des corrélations : projection des variables sur le plan CP1-CP2

CP1 est un axe de charge morbide globale : il oppose le pôle fragilité (mauvaise santé perçue, difficulté à marcher, diabète, hypertension) au pôle aisance (revenu, études, activité physique). CP2 est un axe d'âge et de rapport aux soins : il oppose les personnes âgées, assurées et suivies à celles qui renoncent aux soins pour raison financière. La dimension de l'accès aux soins apparaît donc dès

l'ACP.




Répondants projetés sur le plan principal, coloriés selon leur statut réel (non utilisé par l'ACP)

Les personnes atteintes se déplacent vers le pôle « charge morbide » sans former de bloc isolé : le signal existe mais il est diffus et non linéaire — d'où l'intérêt du clustering pour en tirer des profils exploitables.

3. Le choix du nombre de groupes

Le k-means impose de fixer le nombre de groupes k . Deux critères classiques l'éclairent : la méthode du coude (inertie intra-cluster) et le score de silhouette (qualité de séparation des groupes).



Méthode du coude et score de silhouette selon k


$k = 4$: le choix de l'interprétabilité

La silhouette est maximale pour $k=2$ ou $k=3$, mais toutes ses valeurs sont faibles ($\sim 0,1$ à $0,2$) : avec des variables binaires, les groupes se chevauchent, et la silhouette — qui récompense des clusters bien séparés — n'est pas un juge fiable ici. La méthode du coude, elle, décroît régulièrement sans coude franc. Le critère décisif devient donc l'interprétabilité : un $k=2$ se contenterait de séparer « sains » et « fragiles », un découpage binaire trivial. Avec $k=4$, on obtient quatre profils de population distincts et nommables, avec un gradient de risque étendu. C'est le bon compromis entre finesse et clarté.


4. Profils de population (k-means)

Le k-means répartit les 253 680 répondants en quatre profils. Le tableau ci-dessous les présente par risque croissant.

Profil (risque croissant)	Effectif	Taux maladie
0 — Jeunes actifs en bonne santé	113 279	1,6 %
1 — Adultes non assurés	12 269	6,6 %
2 — Seniors autonomes	87 922	13,0 %
3 — Seniors multi-morbides fragiles	40 210	24,5 %



Signature de chaque profil : écart à la moyenne, en écarts-types (rouge = au-dessus)



Taux de maladie cardiaque par profil

4.1 Lecture des quatre profils

Profil 0 — Jeunes actifs en bonne santé (1,6 %). Le plus grand groupe : âge bas, excellente santé perçue, IMC modéré (26,5), forte activité physique, revenus et études élevés. Population de référence, quasiment épargnée.

Profil 1 — Adultes non assurés (6,6 %). Signature sociale, pas médicale : 0 % seulement ont une

couverture santé (contre 95 % dans la population) et 37 % ont renoncé à un médecin pour raison financière. Adultes plus jeunes, aux revenus modestes. Que le clustering ait isolé ce groupe à partir de variables surtout médicales est remarquable : il a retrouvé une fracture d'accès aux soins.

Profil 2 — Seniors autonomes (13,0 %). Personnes âgées mais en forme : hypertension et cholestérol fréquents (souvent traités), mais bonne mobilité (8 % de difficulté à marcher seulement), activité maintenue. L'âge les expose, l'état fonctionnel les protège.

Profil 3 — Seniors multi-morbides fragiles (24,5 %, le risque le plus élevé). Cumul de pathologies : diabète fréquent, forte difficulté à marcher (78 %), mauvaise santé perçue, IMC élevé (31,5), faible activité. Groupe cible prioritaire d'une prévention.


Deux découvertes

Le clustering, qui n'a jamais vu la maladie, sépare la population selon un risque de 1,6 % à 24,5 % — un rapport de 1 à 15. Il distingue deux populations âgées que l'âge seul confondrait (autonomes vs fragiles ; c'est la mobilité et le diabète qui les séparent), et il isole une fracture d'accès aux soins (les non-assurés). Les déterminants sociaux structurent la population autant que les facteurs cliniques.

5. Validation : CAH et t-SNE

5.1 Classification ascendante hiérarchique

La CAH fusionne progressivement les individus les plus proches et se lit sur un dendrogramme. Menée indépendamment du k-means (sur un échantillon de 3 000 répondants, la méthode ayant un coût en $O(n^2)$), elle vérifie la cohérence de la structure.




Dendrogramme (méthode de Ward), coupé à quatre groupes

Les regroupements se forment à des hauteurs nettes, cohérents avec un découpage en quelques groupes aux taux de maladie contrastés. Deux méthodes de logiques différentes convergent : la population se structure en une poignée de profils.

5.2 Projection t-SNE

Le t-SNE projette les données en 2D en préservant les proximités locales. Il permet de voir si les profils correspondent à des régions distinctes.



t-SNE : à gauche coloré par profil k-means, à droite par statut réel

Les profils occupent des régions cohérentes. Les seniors autonomes et fragiles se chevauchent en partie (chevauchement attendu), mais le profil des non-assurés forme un îlot nettement isolé — le groupe le plus distinct de la carte, ce qui valide sa découverte. À droite, les personnes atteintes se concentrent dans les régions des profils à haut risque, alors que la cible n'a jamais été utilisée.

6. Synthèse et apport au machine learning

- L'ACP révèle une structure multidimensionnelle : le signal est réel mais diffus, réparti sur de nombreuses variables peu redondantes.
- Quatre profils de population, de risque 1,6 % à 24,5 %, émergent sans recours à la cible.
- CAH et t-SNE confirment la structure par des méthodes indépendantes.
- Deux découvertes actionnables : la fragilité fonctionnelle (mobilité, diabète) distingue mieux le risque que l'âge seul ; et l'accès aux soins dessine un groupe à part.

Ce que cela implique pour la modélisation

Le signal étant réel mais diffus et non linéaire (ACP peu compressive, groupes qui se chevauchent), des modèles non linéaires — arbres et méthodes d'ensemble — devraient surpasser une régression logistique simple. Les profils suggèrent des interactions (âge × mobilité, âge × diabète) que le modèle devra capter. Et aucune variable ne domine à elle seule : c'est la combinaison des facteurs qui fait le risque.

Résultats reproductibles depuis l'entrepôt (graine fixe). Source des données : BRFSS, CDC, édition 2015 ; données publiques via Kaggle.