

Documentation technique

ETL & Analyse exploratoire

BRFSS Heart Analytics

Analyse et prédiction du risque cardiovasculaire
à partir des données du Behavioral Risk Factor
Surveillance System (CDC, 2015)

Ahmed Ben Arfa

20/07/2026

github.com/AhmedBenArfa/BRFSS-Heart-Analytics

1. Introduction et objectifs

Ce document décrit la première phase du projet BRFSS Heart Analytics : la construction du pipeline ETL et l'analyse exploratoire des données. Il présente les choix techniques retenus, les contrôles qualité mis en place et les résultats de l'exploration, en explicitant systématiquement les raisons de chaque décision.

1.1 Objectif du projet

Estimer le risque de maladie ou d'accident cardiaque d'une personne à partir de son profil de santé déclaré, et identifier les facteurs les plus fortement associés à ce risque. Le projet couvre l'ensemble de la chaîne analytique : extraction et nettoyage, entrepôt de données dimensionnel, restitution décisionnelle, modélisation prédictive, puis mise à disposition via une application web.

1.2 Objectif de cette phase

- Construire un pipeline ETL reproductible, de la donnée brute vers une table analytique exploitable.
- Mettre en place des contrôles qualité automatiques qui empêchent toute donnée inattendue de se propager silencieusement.
- Comprendre la structure des données et identifier les facteurs associés à la maladie cardiovasculaire.
- Établir les contraintes que l'exploration impose à la phase de modélisation.

Limite méthodologique fondamentale

Les 21 variables explicatives sont auto-déclarées au même moment que la variable cible, lors d'un unique entretien téléphonique. Les relations décrites dans ce document sont donc des associations transversales : elles ne permettent d'établir ni causalité, ni prédiction d'un événement futur. Le modèle qui en découlera estime un risque à partir d'un profil, il ne prédit pas la survenue d'un accident cardiaque. Cette limite est rappelée dans tous les livrables du projet, y compris l'application web.

2. Le jeu de données

2.1 Source et volumétrie

Les données proviennent du Behavioral Risk Factor Surveillance System (BRFSS), enquête téléphonique annuelle menée par les Centers for Disease Control and Prevention (CDC) aux États-Unis. L'édition 2015 utilisée ici a été mise à disposition sur Kaggle dans une version déjà nettoyée et encodée.

Propriété	Valeur
Nombre de répondants	253 680
Variables après enrichissement	31
Valeurs manquantes	0
Variable cible	heart_disease (0 / 1)
Prévalence de la cible	9,42 %
Licence	Données publiques

L'absence totale de valeurs manquantes (0 sur l'ensemble du fichier) est inhabituelle et mérite d'être soulignée : elle résulte du nettoyage préalable appliqué par l'auteur du jeu Kaggle, qui a écarté les non-réponses. Aucune stratégie d'imputation n'est donc nécessaire, mais il faut garder à l'esprit que cette sélection en amont a pu écarté des profils particuliers — les personnes les plus fragiles étant généralement celles qui répondent le moins.

2.2 Dictionnaire des variables

Les 22 variables de la source se répartissent en cinq groupes.

Conditions médicales déclarées

Variable	Description	Modalités
HighBP	Hypertension artérielle diagnostiquée	0 / 1
HighChol	Cholestérol élevé diagnostiqué	0 / 1
CholCheck	Dosage du cholestérol depuis 5 ans	0 / 1
Stroke	Antécédent d'accident vasculaire cérébral	0 / 1
Diabetes	Statut diabétique	0 / 1 / 2
DiffWalk	Difficulté sérieuse à marcher	0 / 1

Comportements et hygiène de vie

Variable	Description	Modalités
Smoker	A fumé au moins 100 cigarettes dans sa vie	0 / 1
PhysActivity	Activité physique dans les 30 derniers jours	0 / 1
Fruits	Consommation de fruits au moins 1 fois/jour	0 / 1
Veggies	Consommation de légumes au moins 1 fois/jour	0 / 1
HvyAlcoholConsump	Consommation d'alcool excessive	0 / 1

État de santé perçu et mesures

Variable	Description	Modalités
GenHlth	État de santé général perçu	1 à 5
MentHlth	Jours de mal-être mental sur 30	0 à 30
PhysHlth	Jours de mal-être physique sur 30	0 à 30
BMI	Indice de masse corporelle	12 à 98

Accès aux soins et données socio-démographiques

Variable	Description	Modalités
AnyHealthcare	Dispose d'une couverture santé	0 / 1
NoDocbcCost	A renoncé à un médecin pour raison financière	0 / 1
Sex	Sexe déclaré	0 / 1
Age	Tranche d'âge (codebook BRFSS)	1 à 13
Education	Niveau d'études atteint	1 à 6
Income	Tranche de revenu du foyer	1 à 8

Un point d'attention sur l'encodage

Toutes les variables sont livrées en float64, y compris les indicateurs binaires et les codes ordinaux. Sans retraitement, une tranche d'âge s'afficherait « 9,0 » dans les rapports décisionnels. Le pipeline rétablit des types entiers, et les libellés du codebook BRFSS sont réintégrés au niveau de l'entrepôt afin de restituer « 60-64 ans ».


3. Architecture du pipeline ETL

3.1 Principe directeur

Aucune donnée n'est supprimée ni corrigée

Le pipeline ne modifie jamais une valeur au motif qu'elle paraît improbable. Les anomalies sont signalées par des drapeaux booléens, et la table analytique reste fidèle à la source. Les décisions de traitement — exclure, imputer, transformer — appartiennent aux étapes aval, où elles sont prises en connaissance de cause et documentées. Ce choix garantit qu'aucune information n'est perdue de façon irréversible dès l'entrée du pipeline.

3.2 Enchaînement des étapes



3.3 Rôle de chaque module

Fichier	Responsabilité
config.py	Chemins, codebook, domaines de validation, seuils
extract.py	Lecture du CSV source, gestion du mode échantillon
transform.py	Nettoyage, typage, enrichissement, drapeaux qualité
checks.py	Contrôles qualité avant chargement
load.py	Écriture dans DuckDB, gestion du verrou d'écriture
run_etl.py	Orchestration et restitution de l'exécution

Cette séparation en modules à responsabilité unique permet de tester chaque étape isolément et de modifier une règle métier sans toucher au reste de la chaîne. Le fichier `config.py` centralise toutes les constantes : aucun autre module ne code en dur un chemin, un seuil ou un libellé.

3.4 Contrôles qualité

Les contrôles se répartissent en deux niveaux de sévérité. Les contrôles bloquants interrompent le pipeline : table vide, identifiant non unique, valeur manquante, variable hors du domaine défini par le codebook, ou mesure hors de ses bornes connues. Les alertes sont affichées puis consignées sans interrompre l'exécution : écart de volumétrie, prévalence inhabituelle, taux d'IMC extrêmes élevé.

L'intérêt du contrôle de domaine mérite d'être souligné : si le fichier source venait à changer — nouvelle édition du BRFSS, encodage différent, colonne renommée — le pipeline s'arrêterait avec un message explicite plutôt que de charger silencieusement des données incorrectes dans l'entrepôt.

3.5 Exécution

```
cd 01_etl
python run_etl.py                # pipeline complet
python run_etl.py --sample 5000  # échantillon, pour tester
```

L'exécution complète traite les 253 680 lignes en moins d'une seconde.

4. Variables dérivées

Le pipeline enrichit la source de variables métier absentes du fichier d'origine. Elles résument des informations dispersées sur plusieurs colonnes et se révèlent, pour certaines, plus informatives que les variables brutes dont elles sont issues.


Variable	Définition
bmi_class	Classe d'IMC selon les seuils de l'OMS (6 modalités)
total_unhealthy_days	Jours de mal-être mental + physique, plafonné à 30
risk_factor_count	Cumul des facteurs de risque cardiovasculaire (0 à 7)
healthy_habits_count	Cumul des comportements protecteurs (0 à 3)
has_care_access	Couverture santé et absence de renoncement financier

4.1 Le score de facteurs de risque

La variable risk_factor_count compte les facteurs de risque cardiovasculaire reconnus présents chez un répondant : hypertension, cholestérol élevé, tabagisme, antécédent d'AVC, difficulté à marcher, diabète et obésité. Sa capacité discriminante est remarquable.

Facteurs de risque	Effectif	Prévalence
0	44 325	1,19 %
1	64 232	2,91 %
2	57 632	7,36 %
3	43 430	13,59 %
4	25 990	20,34 %
5	13 117	30,08 %
6	4 371	40,63 %
7	583	59,18 %

La progression est strictement monotone et couvre une amplitude considérable : de 1,19 % chez les répondants sans aucun facteur de risque à 59,18 % chez ceux qui en cumulent sept, soit un rapport de 1 à 50. Cette variable unique, construite à partir de sept colonnes, capture une part importante du signal disponible.



Effectifs et prévalence selon le nombre de facteurs de risque cumulés

5. Qualité des données : le cas des doublons

Le jeu contient 23 899 lignes strictement identiques à une autre soit 9,42 % de l'échantillon. Le réflexe habituel consiste à les supprimer. Cette décision mérite pourtant d'être instruite car elle repose sur une hypothèse implicite qu'il est possible de tester.

5.1 Deux hypothèses concurrentes

Hypothèse A — erreurs de saisie : un même répondant a été enregistré plusieurs fois. Les doublons sont alors des artefacts à éliminer.


Hypothèse B — collisions légitimes : avec 22 variables toutes grossièrement codées (indicateurs binaires, tranches d'âge, classes de revenu), deux personnes différentes peuvent parfaitement présenter le même profil. Les doublons sont alors de vrais répondants distincts.

Ces deux hypothèses produisent des prédictions opposées et vérifiables. Quatre tests permettent de trancher.

5.2 Test 1 — sensibilité à la taille de l'échantillon

Si les doublons résultent d'erreurs de saisie, leur taux est une propriété intrinsèque du fichier : il doit rester constant quelle que soit la taille de l'échantillon considéré. S'il s'agit de collisions, le taux doit croître avec la taille — plus il y a de répondants, plus la probabilité que deux d'entre eux coïncident augmente, selon la logique du paradoxe des anniversaires.

Taille de l'échantillon	Lignes dupliquées
12 684	1,50 %
25 368	2,55 %
63 420	4,47 %
126 840	6,69 %
253 680	9,42 %



Le taux de doublons croît avec la taille de l'échantillon, ce qui exclut l'hypothèse d'erreurs de saisie

Le taux est multiplié par plus de six entre le plus petit et le plus grand échantillon. L'hypothèse A est écartée.

5.3 Test 2 — nature des profils dupliqués

Une erreur de saisie n'a aucune raison de viser préférentiellement certains profils : elle devrait frapper au hasard. Une collision, en revanche, touche d'abord les profils les plus fréquents dans la population.

Caractéristique	Lignes dupliquées	Lignes uniques
Aucun jour de mal-être mental	95,7 %	65,0 %
Aucun jour de mal-être physique	96,2 %	57,8 %
IMC inférieur ou égal à 30	91,1 %	67,9 %

Les lignes dupliquées sont massivement des profils banals : personnes en bonne santé, IMC modéré, aucun jour de mal-être déclaré. C'est exactement le comportement attendu de collisions.

5.4 Test 3 — taille des groupes

La distribution des groupes de doublons décroît régulièrement, et le groupe le plus important compte 59 lignes rigoureusement identiques. Aucun mécanisme d'erreur de saisie plausible ne produit 59 copies d'un même enregistrement. En revanche, que 59 répondants sur plus de 250 000 partagent le profil le plus commun de la population est parfaitement attendu.

5.5 Test 4 — conséquence d'une déduplication

Traitement	Prévalence de la cible
Doublons conservés	9,419 %
Doublons supprimés	10,322 %
Écart introduit	+0,903 point

Décision : les doublons sont conservés

Les quatre tests convergent vers l'hypothèse des collisions légitimes. Supprimer ces lignes reviendrait à effacer de vrais répondants, majoritairement en bonne santé, et ferait mécaniquement grimper la prévalence de la maladie de 9,42 % à 10,32 %. La déduplication n'aurait pas nettoyé les données : elle les aurait biaisées.


5.6 Un point connexe à traiter en modélisation

L'analyse des doublons met en lumière une propriété distincte : des profils rigoureusement identiques portent parfois des valeurs cibles opposées — deux personnes au même profil déclaré, l'une atteinte, l'autre non. Il ne s'agit pas d'un défaut de qualité mais d'une erreur irréductible, inhérente au fait que 21 variables ne suffisent pas à déterminer entièrement l'état de santé cardiaque. Cette erreur fixe un plafond de performance qu'aucun modèle ne pourra dépasser. Elle sera quantifiée dans la documentation du module de modélisation.

6. Analyse exploratoire

6.1 La variable cible

La prévalence s'établit à 9,42 %, soit environ un répondant atteint pour dix. Ce déséquilibre a des conséquences directes et immédiates sur la méthodologie de modélisation.




Répartition de la variable cible : un déséquilibre marqué

Conséquence : l'exactitude est inutilisable

Avec 9,42 % de cas positifs, un modèle qui prédirait « aucun malade » pour l'ensemble de la population atteindrait 90,58 % d'exactitude tout en étant dépourvu de toute utilité. L'accuracy est donc écartée comme critère de sélection. Les métriques retenues sont le ROC-AUC, le PR-AUC, le rappel et le F1 — cette dernière famille étant adaptée aux classes déséquilibrées.

6.2 Prévalence par segment

Prévalence de la maladie cardiaque par segment (trait = moyenne 9,42 %)



Prévalence de la maladie cardiaque selon six segments (trait pointillé : moyenne générale)

L'âge est de loin le facteur le plus discriminant : la prévalence passe de 0,51 % dans la tranche la plus jeune à 23,95 % chez les 80 ans et plus, selon une progression strictement monotone.


L'état de santé perçu se révèle presque aussi puissant, avec un rapport d'environ un à dix entre les

personnes se déclarant en excellente santé et celles se disant en mauvaise santé. Bien que subjective, cette variable résume une quantité importante d'information clinique.

Un gradient socio-économique net apparaît également : la prévalence décroît régulièrement à mesure que le revenu du foyer et le niveau d'études augmentent.

6.3 La relation non monotone entre IMC et maladie

Classe d'IMC (OMS)	Effectif	Prévalence
Insuffisance pondérale	3 127	10,59 %
Corpulence normale	68 953	6,84 %
Surpoids	93 749	9,30 %
Obésité modérée (I)	53 451	11,10 %
Obésité sévère (II)	20 663	12,16 %
Obésité morbide (III)	13 737	12,26 %



La prévalence selon la classe d'IMC dessine une courbe en J


Ce résultat mérite une attention particulière. Les personnes en insuffisance pondérale présentent une prévalence de 10,59 %, nettement supérieure à celle des personnes de corpulence normale (6,84 %) et proche de celle des obésités modérées. La relation entre IMC et maladie cardiaque n'est donc pas monotone : elle dessine une courbe en J.

Ce phénomène est bien documenté en épidémiologie. Il relève en grande partie de la causalité inverse : la maladie chronique provoque un amaigrissement, plutôt que la maigreur ne cause la maladie. La simultanéité du recueil des variables et de la cible interdit toutefois de trancher sur la base de ces seules données.

Conséquence pour la modélisation

Un modèle linéaire appliqué à l'IMC brut manquerait entièrement cette structure : il conclurait à une relation croissante là où les deux extrémités de la distribution présentent un risque élevé. Cela justifie de conserver la classe d'IMC catégorielle en complément de la valeur continue, et oriente vers les modèles à base d'arbres, capables de capturer ce type de non-linéarité sans transformation préalable.

6.4 Structure des corrélations




Matrice des corrélations de Pearson entre les principales variables

Variable	Corrélation avec la cible
gen_hlth	+0,258
age_group	+0,222
diff_walk	+0,213
high_bp	+0,209
stroke	+0,203
phys_hlth_days	+0,182
high_chol	+0,181
diabetes	+0,180

Aucune corrélation linéaire n'est forte : la plus élevée atteint 0,258 en valeur absolue. Ce constat ne doit pas conduire à penser que les variables sont peu informatives. La plupart d'entre elles sont binaires, et le coefficient de Pearson mesure mal les relations non linéaires — la courbe en J de l'IMC en est l'illustration directe. Le gradient observé sur le cumul des facteurs de risque démontre au contraire l'existence d'un signal très net.

Aucune paire de variables explicatives ne présente de corrélation forte : il n'y a pas de multicollinéarité problématique, et l'ensemble des variables peut être conservé.

6.5 Comparaison des profils



Fréquence des indicateurs selon le statut cardiaque

Les écarts les plus marqués concernent la difficulté à marcher, l'antécédent d'AVC, l'hypertension et le cholestérol élevé. L'activité physique constitue le seul indicateur nettement plus fréquent chez les personnes non atteintes.


Un résultat à ne pas mal interpréter

La consommation excessive d'alcool apparaît paradoxalement plus fréquente chez les répondants non atteints. Il ne faut pas y voir un effet protecteur : les gros consommateurs déclarés sont en moyenne nettement plus jeunes, et l'âge domine largement le risque cardiovasculaire. Il s'agit d'un effet de structure, illustration classique du fait qu'une association brute ne se lit jamais indépendamment des variables de confusion.

7. Valeurs aberrantes et standardisation

Deux questions distinctes, souvent confondues, doivent être traitées séparément avant la modélisation. La première : le jeu contient-il des valeurs aberrantes, c'est-à-dire des valeurs fausses issues d'une erreur de saisie ou de mesure ? La seconde : faut-il standardiser les variables ? La seconde ne découle pas de la première.

7.1 Distribution par statut



Boîtes à moustaches des variables continues selon le statut cardiaque

Le contraste le plus frappant concerne les jours de mal-être physique. Chez les non atteints, la boîte est écrasée sur zéro. Chez les personnes atteintes, elle s'étale de 0 à 20 : un quart d'entre elles déclarent au moins vingt jours de souffrance physique sur les trente derniers. Le cumul des facteurs de risque offre également une séparation nette, supérieure à celle de n'importe quelle variable brute prise isolément.

7.2 Deux règles classiques qui se contredisent

L'application des deux règles usuelles de détection — l'écart interquartile et le z-score au-delà de trois écarts-types — produit des résultats incompatibles.

Variable	Max	Seuil IQR	Seuil $z=3$	% hors IQR	% $ z >3$
bmi	98,0	41,5	48,2	3,88 %	1,17 %
ment_hlth_days	30,0	5,0	25,4	14,27 %	5,01 %
phys_hlth_days	30,0	7,5	30,4	16,14 %	0,00 %

Pour l'IMC, les deux règles restent cohérentes. Pour `phys_hlth_days`, en revanche, l'écart interquartile signale 16,14 % de l'échantillon là où le z-score n'en signale aucun. L'explication est structurelle : la variable est bornée à 30 par le questionnaire, et son seuil à trois écarts-types s'établit à 30,4 — une valeur inatteignable par construction. Le seuil de l'IQR tombe quant à lui à 7,5 et coupe en pleine distribution légitime.

La notion de valeur aberrante ne s'applique pas ici

Ces variables sont bornées et présentent une forte inflation de zéros. Les deux règles classiques supposent une distribution approximativement symétrique et non bornée : aucune des deux n'est valide dans ce contexte. Appliquer l'écart interquartile de façon mécanique conduirait à écarter environ quarante mille réponses parfaitement valides — précisément celles des personnes en souffrance, c'est-à-dire celles qui portent le signal recherché.

7.3 Examen des valeurs extrêmes

Les IMC supérieurs à 60

Ils concernent 805 lignes soit 0,32 % de l'échantillon. Un IMC de 98 supposerait par exemple une masse de 285 kg pour une taille de 1 70 m — physiologiquement très improbable. Un élément est

révélateur : leur prévalence de maladie cardiaque s'établit à 8,94 % soit une valeur inférieure à la moyenne générale de 9,42 %. S'il s'agissait de cas d'obésité extrême authentiques on attendrait l'inverse l'obésité massive majorant nettement le risque cardiaque. Cette absence de signal suggère du bruit de saisie plutôt que des mesures réelles.

Ces valeurs sont néanmoins conservées et signalées par le drapeau `flag_bmi_extreme`. Représentant moins d'un demi-pour-cent de l'échantillon, elles ne pèseront pas sur l'apprentissage, et les supprimer constituerait une décision arbitraire que rien n'impose.


Les trente jours de mal-être

Ils relèvent d'une logique opposée. Il ne s'agit pas d'une anomalie mais de la borne du questionnaire : nul ne peut déclarer plus de trente jours sur trente. Le signal qu'ils portent est considérable — parmi les 19 400 répondants déclarant trente jours de souffrance physique 23,86 % sont atteints contre 9,42 % en moyenne soit 2,5 fois plus. Ces observations comptent parmi les plus informatives du jeu de données ; les traiter comme aberrantes détruirait précisément ce que l'on cherche à modéliser.

Décision : aucune valeur supprimée ni winsorisée

Les valeurs extrêmes sont signalées par des drapeaux et conservées. Les modèles robustes à ce type de valeurs — arbres de décision et méthodes d'ensemble — seront privilégiés lors de la phase de modélisation.

7.4 La justification réelle de la standardisation



Étendue des variables avant et après centrage-réduction

L'argument en faveur de la standardisation ne repose pas sur les valeurs extrêmes mais sur l'hétérogénéité des échelles. L'IMC s'étend sur près de quatre-vingt-dix unités quand les indicateurs binaires n'en couvrent qu'une seule : le rapport entre la plus grande et la plus petite étendue atteint 86 pour 1. Après centrage-réduction, ce rapport tombe à 6,5 pour 1.

Pour tout algorithme fondé sur une distance ou sur une régularisation pénalisant l'amplitude des coefficients, l'IMC écraserait mécaniquement les autres variables — non parce qu'il serait plus informatif, mais parce qu'il est numériquement plus grand.

Famille de modèle	Standardisation	Raison
kNN, SVM	Indispensable	Fondés sur des distances
Régression logistique pénalisée	Nécessaire	La pénalité dépend de l'échelle
Arbres, forêts, XGBoost	Inutile	Seuils invariants par changement d'échelle

Décision retenue

La standardisation est intégrée au ColumnTransformer du pipeline de modélisation, ajusté sur le seul jeu d'entraînement puis appliqué au jeu de test — faute de quoi les statistiques du test fuiteraient dans l'apprentissage. Elle est conservée y compris pour les modèles à base d'arbres, où elle est neutre, afin que tous les modèles partagent exactement le même préprocessing et demeurent rigoureusement comparables.

8. Synthèse et implications

8.1 Bilan qualité

Point examiné	Constat	Décision
Valeurs manquantes	Aucune	Pas d'imputation
Doublons exacts	23 899	Conservés (collisions)
IMC extrêmes	832	Signalés, conservés
Incohérences santé	7 213	Signalées, légitimes

8.2 Facteurs associés, par ordre d'importance

- L'âge — de 0,51 % à 23,95 % de prévalence selon la tranche.
- L'état de santé perçu — rapport d'environ un à dix.
- Le cumul des facteurs de risque — de 1,19 % à 59,18 %.
- L'antécédent d'AVC, la difficulté à marcher, l'hypertension et le cholestérol élevé.
- Le gradient socio-économique — revenu et niveau d'études.

8.3 Contraintes imposées à la modélisation

L'analyse exploratoire ne se contente pas de décrire : elle contraint les choix méthodologiques de la phase suivante.

- Écarter l'exactitude comme critère : à 9,42 % de cas positifs, un modèle constant atteindrait 90,58 %. Retenir le ROC-AUC, le PR-AUC, le rappel et le F1.
- Traiter explicitement le déséquilibre des classes par pondération, en comparant avec une approche par rééchantillonnage synthétique.
- Privilégier les modèles non linéaires : la courbe en J de l'IMC et la faiblesse des corrélations de Pearson établissent que le signal n'est pas linéaire.
- Quantifier l'erreur irréductible liée aux profils identiques de cibles opposées, afin de connaître le plafond de performance atteignable.
- Ajuster le préprocessing sur le seul jeu d'entraînement, pour éviter toute fuite d'information.
- Maintenir la prudence interprétative : les relations établies sont des associations transversales et non des liens de causalité.

Annexe — Reproduire ces résultats

L'ensemble des résultats présentés dans ce document est reproductible à partir du dépôt cloné.

```
# 1. Installer les dépendances
pip install -r requirements.txt

# 2. Exécuter le pipeline ETL
cd 01_etl
python run_etl.py

# 3. Régénérer et exécuter le notebook d'analyse exploratoire
cd notebooks
python _build_eda.py
python -m jupyter nbconvert --to notebook --execute --inplace 01_eda.ipynb

# 4. Régénérer ce document
cd ../../06_rapport
python _build_doc_pdf_eda.py
```

Sur la génération de ce document

Ce rapport est produit par un script qui recalcule chaque statistique depuis l'entrepôt DuckDB au moment de la génération, et qui intègre les figures effectivement produites par le notebook. Aucun chiffre n'y est saisi manuellement : le document ne peut donc pas diverger des données qu'il décrit. Les notebooks obéissent au même principe et sont produits par des scripts générateurs.

Source des données : Behavioral Risk Factor Surveillance System (BRFSS), Centers for Disease Control and Prevention, édition 2015. Jeu de données public diffusé via Kaggle.