

Documentation technique

Machine Learning

BRFSS Heart Analytics

Préparation, préprocessing, comparaison de six modèles,
diagnostic et interprétation
(BRFSS, CDC, 2015)

Ahmed Ben Arfa

21/07/2026

github.com/AhmedBenArfa/BRFSS-Heart-Analytics

1. Objectif et cadre

Cette phase construit un modèle capable d'estimer, à partir d'un profil de santé déclaré, la probabilité qu'une personne présente une maladie ou un accident cardiaque, puis d'identifier les facteurs déterminants.

Limite méthodologique

Les variables explicatives sont auto-déclarées au même moment que la cible. Le modèle mesure une association transversale : il estime un risque à partir d'un profil, il ne prédit pas la survenue future d'un accident cardiaque. Toute lecture causale est exclue.

1.1 Ce que les phases précédentes imposent

Constat établi	Conséquence
Cible à 9,42 % de positifs	Exactitude inutilisable
Signal diffus (ACP peu compressive)	Tester des modèles non linéaires
Interactions suggérées par le clustering	Inclure arbres et ensembles
Relation en J de l'IMC	Le linéaire brut manquerait la structure
Échelles très hétérogènes (86 pour 1)	Standardisation obligatoire

2. Préparation des données

2.1 Sélection des variables

Le modèle utilise les 21 variables d'origine de l'enquête. Trois familles de colonnes ont été volontairement écartées :

- La cible elle-même, évidemment.
- Les variables dérivées produites par l'ETL (score de facteurs de risque, jours de mal-être cumulés, classe d'IMC). Elles sont des fonctions déterministes des colonnes conservées : les inclure n'ajouterait aucune information, mais introduirait de la redondance, gênerait la lecture des importances et donnerait un poids artificiel aux variables comptées plusieurs fois.
- Les drapeaux qualité (IMC extrême, profil dupliqué). Ils décrivent la donnée, pas le répondant : les utiliser reviendrait à laisser le modèle exploiter un artefact de collecte.

2.2 Découpage stratifié

Le jeu est séparé en 202 944 lignes d'entraînement et 50 736 lignes de test (80 / 20) avec **stratification** sur la cible.

La stratification garantit que la proportion de cas positifs est identique dans les deux jeux. Sans elle, un tirage malchanceux pourrait produire un jeu de test à la prévalence sensiblement différente : l'évaluation finale mesurerait alors autant la chance du tirage que la qualité du modèle. Avec seulement 9,42 % de positifs, ce risque est loin d'être théorique.

Le jeu de test est mis sous scellés

Le jeu de test n'est utilisé qu'une seule fois, à la toute fin, pour l'évaluation. Toute la sélection — choix des modèles, réglage des hyperparamètres, stratégie de déséquilibre, diagnostic — s'effectue par validation croisée sur le seul jeu d'entraînement. Consulter le test plusieurs fois pour orienter des décisions reviendrait à l'utiliser comme un jeu de validation, et l'estimation finale serait optimiste.

3. Préprocessing : transformations et encodage

Le préprocessing est assemblé dans un `ColumnTransformer`, lui-même intégré à un `Pipeline` `scikit-learn`. Les 21 variables sont réparties en trois groupes, chacun recevant un traitement adapté à sa nature.

Groupe	Variables	Traitement
Continues	bmi, ment_hlth_days, phys_hlth_days	StandardScaler
Ordinales	gen_hlth, age_group, education, income, diabetes	StandardScaler
Binaires	13 indicateurs 0/1	passthrough (aucun)

3.1 La standardisation : ce qu'elle fait et pourquoi

La standardisation (centrage-réduction) transforme chaque variable pour lui donner une moyenne de 0 et un écart-type de 1, en appliquant à chaque valeur la transformation suivante :

$$z = (x - \text{moyenne}) / \text{écart-type}$$

La transformation est **linéaire et strictement monotone** : elle ne déforme ni la distribution, ni l'ordre des valeurs. Une personne dont l'IMC est supérieur à celui d'une autre le reste après transformation. Seule l'unité de mesure change.

Pourquoi c'est indispensable ici

L'analyse exploratoire a mesuré un rapport de 86 pour 1 entre la plus grande et la plus petite étendue de variables : l'IMC s'étale sur près de 90 unités quand un indicateur binaire n'en couvre qu'une seule. Pour tout algorithme fondé sur des distances ou sur une pénalisation, l'IMC écraserait mécaniquement les autres variables — non parce qu'il serait plus informatif, mais parce qu'il est numériquement plus grand. Après standardisation, ce rapport tombe à 6,5 pour 1.

Famille de modèle	Standardisation	Raison
kNN	Indispensable	Distances euclidiennes
SVM	Indispensable	Marge définie par des distances
Régression logistique pénalisée	Nécessaire	La pénalité L2 dépend de l'échelle
Arbre, forêt, XGBoost	Neutre	Seuils invariants par transformation monotone

Pourquoi standardiser aussi pour les arbres

Les modèles à base d'arbres découpent selon des seuils : une transformation monotone ne change strictement rien à leurs résultats. La standardisation leur est donc neutre. Elle est néanmoins appliquée à tous les modèles, afin que la comparaison porte uniquement sur les algorithmes et non sur des préparations différentes. Un écart de performance ne peut ainsi jamais s'expliquer par un préprocessing plus favorable à l'un.

L'ajustement se fait sur le seul jeu d'entraînement

Point méthodologique central. Le `StandardScaler` doit calculer une moyenne et un écart-type : ces statistiques sont estimées **uniquement** sur les données d'entraînement, puis appliquées telles quelles au test. En validation croisée, l'opération est refaite à chaque pli, sur le seul pli d'apprentissage.

Fuite de données : l'erreur à ne pas commettre

Standardiser l'ensemble du jeu AVANT le découpage constitue une fuite de données : les moyennes et écarts-types incorporeraient de l'information issue du test, que le modèle exploiterait indirectement. Les scores obtenus seraient optimistes et ne se reproduiraient pas en production. Placer le préprocesseur dans le `Pipeline` rend cette erreur structurellement impossible : `scikit-learn` n'appelle jamais `fit()` sur autre chose que les données d'apprentissage du moment.

3.2 Encodage des variables : pourquoi pas de OneHotEncoder

L'encodage one-hot (OneHotEncoder) transforme une variable catégorielle en autant de colonnes binaires qu'elle a de modalités. C'est une étape quasi systématique en machine learning — mais **elle n'est pas utilisée ici**, et ce choix mérite d'être justifié précisément.

Les variables binaires : déjà encodées

Les 13 indicateurs (hypertension, tabagisme, activité physique...) sont déjà codés 0/1. Un encodage one-hot produirait deux colonnes parfaitement complémentaires, dont l'une serait redondante — c'est le piège classique de la colinéarité parfaite (dummy trap). Ces variables sont donc transmises telles quelles.

Les variables ordinales : l'ordre porte l'information

C'est le cas le plus intéressant. Des variables comme `gen_hlth` (1 = excellente à 5 = mauvaise), `age_group` (1 à 13), `education` (1 à 6), `income` (1 à 8) ou `diabetes` (0 = non, 1 = prédiabète, 2 = diabète) sont **ordinales** : leurs modalités sont naturellement ordonnées.

Les encoder en one-hot **détruirait cette information d'ordre**. Le modèle traiterait « 60-64 ans » et « 18-24 ans » comme deux catégories sans relation, au même titre que deux couleurs. Il devrait alors réapprendre l'ordre à partir des seules données, en consommant des degrés de liberté pour reconstituer ce que l'on sait déjà. On perdrait aussi la capacité d'extrapoler la monotonie : l'analyse exploratoire a montré que le risque croît régulièrement avec l'âge, information qu'un traitement numérique capture directement.

Les conserver en numérique préserve l'ordre et donne des modèles plus parcimonieux : 21 colonnes au lieu de plus de 50 après one-hot.

Quand le one-hot aurait été nécessaire

Il serait indispensable pour une variable **nominale** à plusieurs modalités — par exemple un État de résidence, une catégorie socio-professionnelle ou un groupe sanguin. Attribuer les codes 1, 2, 3 à trois États imposerait un ordre et des écarts arbitraires, que le modèle prendrait au sérieux. Le jeu BRFSS retenu ne contient aucune variable de ce type : toutes sont binaires, ordinales ou continues. L'absence d'encodage one-hot n'est donc pas un oubli, mais la conséquence de la nature des données.

Une limite assumée du traitement ordinal

Traiter une variable ordinale comme numérique suppose implicitement que l'écart entre modalités consécutives est constant — que passer de « 18-24 » à « 25-29 » équivaut à passer de « 75-79 » à « 80 et plus ». C'est une approximation. Les modèles à base d'arbres s'en affranchissent naturellement (ils choisissent librement leurs seuils de coupure), tandis que la régression logistique en subit la contrainte. La classe d'IMC conservée dans l'entrepôt répond au même besoin, la relation en J n'étant pas monotone.

3.3 Absence d'imputation

Aucun imputeur n'est nécessaire : le jeu ne contient aucune valeur manquante, comme établi lors de l'ETL. Cette absence est elle-même une information — le jeu Kaggle a été nettoyé en amont, ce qui a pu écarter des profils particuliers.

4. Le choix des métriques

4.1 Pourquoi l'exactitude est écartée

Un modèle trivial, qui prédirait « personne n'est malade » pour toute la population, atteint **90,58 % d'exactitude** sur le jeu de test, sans détecter un seul malade. Son ROC-AUC vaut 0,5 — la valeur du hasard. Cette référence, calculée explicitement dans le notebook, démontre que l'exactitude est inutilisable sur des classes déséquilibrées.

4.2 Les métriques retenues

Métrique	Ce qu'elle mesure	Rôle
ROC-AUC	Capacité à ordonner les risques, tous seuils confondus	Sélection
PR-AUC	Idem, centrée sur la classe minoritaire	Arbitre
Rappel	Part des malades effectivement détectés	Suivi
Précision	Part de vrais malades parmi les personnes signalées	Suivi
F1	Moyenne harmonique précision / rappel	Suivi

Le ROC-AUC a été retenu comme critère de sélection car il est **indépendant du seuil** : il évalue la capacité intrinsèque du modèle à classer les personnes à risque avant les autres, ce qui correspond exactement à l'usage visé — estimer un risque, non poser un diagnostic. Le PR-AUC sert d'arbitre lorsque deux modèles sont proches, car il est plus sévère en contexte déséquilibré.

Précision et rappel se lisent ensemble

Le rappel seul s'optimise trivialement en déclarant tout le monde malade. La précision seule s'optimise en ne signalant que les cas les plus évidents. Les deux chiffres côte à côte, et eux seuls, décrivent honnêtement le comportement du modèle.

5. L'erreur irréductible : jusqu'où peut-on monter ?

Des profils rigoureusement identiques portent parfois des cibles opposées — deux personnes au même profil déclaré, l'une atteinte, l'autre non. Aucun modèle ne peut départager ces cas. On a tenté de quantifier ce plancher d'erreur.

Mesure	Valeur
Profils distincts	228 705
Profils observés au moins deux fois	11 743
Profils aux cibles contradictoires	1 076
Part de profils uniques	94,9 %

Pourquoi ce calcul ne donne pas de plafond exploitable

La méthode suggérerait une erreur irréductible très faible, donc une exactitude maximale proche de 99 %. Ce serait une conclusion fautive. 95 % des profils ne sont observés qu'une seule fois : par construction, un profil unique ne peut jamais apparaître ambigu, faute de jumeau avec lequel se contredire. Le calcul ne détecte donc l'ambiguïté que sur une minorité de cas et l'ignore mécaniquement ailleurs. Il s'agit d'une borne inférieure, et d'une borne très faible.

Ce que l'on peut affirmer honnêtement : parmi les profils effectivement observés plusieurs fois, une part notable porte des cibles contradictoires. Cela confirme qu'une fraction réelle du risque cardiaque n'est pas explicable par les 21 variables disponibles — génétique, antécédents familiaux, environnement et qualité du suivi médical n'y figurent pas. La vraie erreur irréductible est nécessairement bien supérieure à ce que mesure cette approche, mais elle n'est pas estimable ainsi.

Conséquence pratique : ne pas viser une performance parfaite. Sur ce type de données déclaratives, un ROC-AUC autour de 0,85 constitue un bon résultat ; prétendre faire beaucoup mieux signifierait plutôt une fuite de données.

6. Les six familles de modèles

Six familles ont été retenues, chacune répondant à une logique différente. L'objectif n'est pas d'accumuler des algorithmes mais de couvrir des hypothèses variées sur la forme du signal.

Modèle	Principe	Pourquoi l'inclure
Régression logistique	Frontière linéaire sur le log-odds	Référence interprétable
kNN	Vote des k voisins les plus proches	Approche par similarité
Arbre de décision	Découpages successifs par seuils	Non-linéarité lisible
Forêt aléatoire	Moyenne d'arbres décorrélés	Réduit la variance
XGBoost	Arbres construits séquentiellement	État de l'art tabulaire
SVM linéaire	Hyperplan à marge maximale	Autre logique linéaire

La régression logistique joue un rôle particulier : elle sert de **plancher de référence**. Un modèle complexe qui ne la dépasse pas ne justifie pas sa complexité.

6.1 Réglage par GridSearchCV

Comparer des modèles avec leurs paramètres par défaut n'a aucune valeur : on mesurerait la qualité des valeurs par défaut, pas celle des algorithmes. Chaque famille est donc optimisée par recherche exhaustive sur une grille, en validation croisée stratifiée à 5 plis, avec le ROC-AUC comme critère.

```
GridSearchCV(  
    Pipeline([("prep", ColumnTransformer(...)),  
              ("model", <modèle>)]),  
    param_grid = <grille propre à la famille>,  
    scoring      = {roc_auc, average_precision, recall, precision, f1},  
    refit        = "roc_auc",  
    cv           = StratifiedKFold(n_splits=5, shuffle=True),  
)
```


6.2 La régularisation, famille par famille

La régularisation pénalise la complexité afin d'éviter que le modèle n'apprenne le bruit. Elle prend une forme différente selon l'algorithme, et chaque grille explore explicitement ce levier.

Modèle	Paramètre exploré	Effet
Régression logistique	C (inverse de la pénalité L2)	C petit = coefficients contraints
SVM linéaire	C	Compromis marge / erreurs tolérées
Arbre de décision	max_depth, min_samples_leaf	Limitent la croissance de l'arbre
Forêt aléatoire	max_depth, min_samples_leaf	Idem, + moyenne sur 200 arbres
XGBoost	max_depth, learning_rate, reg_lambda	Profondeur, pas d'apprentissage, pénalité L2
kNN	n_neighbors	k grand = frontière plus lisse

7. Résultats de la comparaison

Modèle	ROC-AUC	PR-AUC	Précision	Rappel	F1
XGBoost	0,8498	0,3773	0,239	0,815	0,370
Forêt aléatoire	0,8479	0,3725	0,249	0,786	0,378
Régression logistique	0,8474	0,3720	0,246	0,793	0,376
SVM linéaire	0,8472	0,3717	0,546	0,127	0,206
Arbre de décision	0,8361	0,3513	0,231	0,799	0,359
kNN	0,8273	0,3271	0,602	0,031	0,059



Comparaison des six familles, chacune à son meilleur réglage

Le modèle retenu est **XGBoost**, avec un ROC-AUC de 0,8498 en validation croisée. Trois enseignements méritent d'être soulignés.

Le réglage change le classement

Avec les paramètres par défaut, la régression logistique devançait les méthodes d'ensemble. Après optimisation, le classement s'inverse. C'est la démonstration qu'une comparaison de modèles non réglés ne prouve rien.

Les écarts entre familles sont minimes

Quelques millièmes de ROC-AUC séparent les quatre meilleurs modèles. Le signal disponible est donc capté par toutes les approches : il n'existe pas de structure exotique que seul un modèle sophistiqué saurait exploiter.

La précision est structurellement basse

Avec 9,42 % de positifs, détecter suffisamment de malades impose mécaniquement de signaler beaucoup de personnes saines. C'est une propriété du problème, non un défaut des modèles.

8. Traitement du déséquilibre : pondération ou SMOTE ?

Deux stratégies s'opposent classiquement. La **pondération** (`class_weight`, `scale_pos_weight`) accroît le poids des erreurs commises sur la classe minoritaire, sans inventer de données. **SMOTE** génère au contraire des exemples synthétiques de la classe minoritaire par interpolation entre voisins proches.

Stratégie	ROC-AUC	PR-AUC	Précision	Rappel	F1
Pondération	0,8498	0,3773	0,239	0,815	0,370
SMOTE	0,8396	0,3532	0,382	0,382	0,382

Sur ces données, la stratégie retenue est **Pondération**. SMOTE est souvent présenté comme supérieur ; la mesure montre que ce n'est pas systématique. À performance équivalente, la pondération est préférable : elle n'introduit aucune donnée synthétique et reste plus simple à défendre.

SMOTE doit être appliqué à l'intérieur de la validation croisée

Générer les exemples synthétiques avant le découpage ferait fuiter des points interpolés dans les plis de validation, qui deviendraient partiellement prévisibles. Les scores seraient artificiellement gonflés. L'emploi d'un Pipeline `imblearn` garantit que SMOTE n'agit que sur le pli d'apprentissage.

9. Diagnostic : surapprentissage et sous-apprentissage


Deux écueils symétriques guettent tout modèle. Le **surapprentissage** survient lorsque le modèle mémorise le bruit du jeu d'entraînement : il excelle sur les données vues et se dégrade ailleurs. Le **sous-apprentissage** traduit au contraire un modèle trop rigide pour capter le signal : il est médiocre partout, y compris en entraînement. Trois analyses complémentaires permettent de trancher.

9.1 Écart entre entraînement et validation

Métrique	Entraînement	Validation	Écart	Écart relatif
ROC-AUC	0,8535	0,8498	+0,0037	0,43 %
PR-AUC	0,3849	0,3773	+0,0076	1,98 %

Un écart relatif inférieur à environ 5 % caractérise un modèle sain ; au-delà de 10 à 15 %, le surapprentissage devient préoccupant. Les valeurs obtenues situent le modèle retenu très en deçà de ce seuil.

9.2 Courbe d'apprentissage




Évolution des scores selon la quantité de données d'entraînement

La courbe d'apprentissage se lit ainsi : des courbes qui convergent vers un score élevé signalent un modèle bien calibré ; un écart persistant trahit de la variance (surapprentissage) ; deux courbes plafonnant bas révèlent du biais (sous-apprentissage) ; une courbe de validation qui monte encore à droite indique que davantage de données seraient utiles.

9.3 Courbe de validation : le bon niveau de complexité

Profondeur	Entraînement	Validation	Écart
1	0,8464	0,8460	+0,0004
2	0,8507	0,8491	+0,0015
3	0,8535	0,8498	+0,0037
4	0,8572	0,8496	+0,0076
6	0,8716	0,8474	+0,0242
8	0,9019	0,8403	+0,0615
10	0,9407	0,8301	+0,1106



Les trois régimes : sous-apprentissage, optimum, surapprentissage

Le tableau est une illustration de manuel. L'écart entre entraînement et validation passe de +0,0004 à +0,1106, tandis que le score de validation culmine à la profondeur 3 puis décline. À droite, le diagnostic est sans ambiguïté : le modèle mémorise le bruit.


Un résultat inattendu : le signal est presque entièrement additif

À gauche, on attendrait un sous-apprentissage marqué. Il est étonnamment léger : des arbres de profondeur 1 — une seule coupure, donc structurellement incapables de représenter la moindre interaction entre variables — atteignent déjà 0,8460 en validation, contre 0,8498 pour l'optimum. Chaque facteur de risque contribue donc à peu près indépendamment des autres. Cela explique définitivement pourquoi la régression logistique reste à quelques millièmes du meilleur modèle, et corrige l'hypothèse formulée lors du data mining, où l'on anticipait un avantage net des modèles non linéaires.

10. Évaluation finale et choix du seuil

Le modèle retenu est réentraîné sur l'intégralité du jeu d'entraînement, puis évalué une seule fois sur le jeu de test, mis sous scellés depuis le début.

Métrique (jeu de test)	Valeur
ROC-AUC	0,8503
PR-AUC	0,3712
Rappel (au seuil retenu)	0,750
Précision (au seuil retenu)	0,270
Seuil de décision	0,5762




Courbe ROC et courbe précision-rappel sur le jeu de test

Le PR-AUC de 0,3712 se compare à une référence du hasard de 0,0942 : l'apport du modèle est net, d'un facteur proche de quatre.

10.1 Le seuil est une décision distincte du choix du modèle

Le modèle produit une probabilité continue ; le seuil la transforme en décision binaire. Le seuil par défaut de 0,5 n'a aucune raison d'être pertinent sur des classes déséquilibrées. Les deux erreurs n'ayant pas le même coût en santé — manquer une personne à risque est plus grave que recommander une vérification inutile — le seuil a été fixé pour atteindre un rappel cible de 75%.

Résultat au seuil retenu	Effectif
Malades correctement détectés	3 585
Malades manqués (faux négatifs)	1 194
Fausses alertes (faux positifs)	9 714
Sains correctement écartés	36 243




Arbitrage précision / rappel selon le seuil, et matrice de confusion

Pour un outil de sensibilisation au risque — et non de diagnostic — cet arbitrage est le bon : mieux vaut inviter quelques personnes en bonne santé à consulter que passer à côté d'une personne réellement exposée.

11. Interprétation par SHAP

Un modèle performant mais opaque est difficile à défendre, a fortiori en santé. Les valeurs SHAP attribuent à chaque variable sa contribution à chaque prédiction, sur un fondement théorique solide issu de la théorie des jeux coopératifs : la contribution d'une variable est sa valeur de Shapley, moyenne de son apport marginal sur tous les ordres d'ajout possibles.



Contribution des variables : chaque point est un répondant

Variable	Importance SHAP moyenne
age_group	0,7310
gen_hlth	0,4566
high_bp	0,3823
sex	0,3588
high_chol	0,3295
smoker	0,1771
stroke	0,1314
diff_walk	0,1247
diabetes	0,1031
income	0,1027

L'âge domine largement, suivi de la santé perçue — exactement le classement établi par l'analyse exploratoire. La cohérence entre trois approches indépendantes (statistiques descriptives, clustering non supervisé, modèle supervisé) constitue un gage de solidité : ce n'est pas l'artefact d'un algorithme particulier.

Trois observations plus fines méritent d'être relevées. Le **sexe** figure parmi les variables les plus influentes, les hommes voyant leur risque estimé nettement relevé. L'**antécédent d'AVC** produit la poussée individuelle la plus forte : rare, mais très informative lorsqu'elle est présente. Enfin le **renoncement aux soins pour raison financière** apparaît parmi les variables mobilisées — écho direct de la découverte du data mining, où le clustering avait isolé un groupe de non-assurés.

12. Sérialisation et mise à disposition

C'est le **pipeline complet** qui est sauvegardé — préprocesseur et modèle réunis dans un seul objet. L'application web appliquera ainsi exactement les mêmes transformations qu'à l'entraînement, ce qui élimine toute une classe de bugs de mise en production (ordre des colonnes, échelles recalculées, encodage divergent).

```
joblib.dump(pipeline_final, "models/heart_model.joblib")

# metadata.json : ce qu'il faut savoir pour utiliser le modèle
{
  "modele": "...", "seuil_decision": ...,
  "variables": [...],          # ordre attendu des colonnes
  "performances_test": {...},  # ce qu'on peut en attendre
}
```

Les métadonnées accompagnent le modèle : un fichier binaire seul ne dit pas quelles variables il attend, dans quel ordre, avec quel seuil, ni quelle performance escompter. Un fichier `resultats.json` complète l'ensemble et sert de source unique aux chiffres de ce document.

13. Synthèse et limites

13.1 Démarche

Étape	Choix retenu
Découpage	Stratifié 80/20, test sous scellés
Préprocessing	ColumnTransformer dans le Pipeline, sans fuite
Encodage	Ordinal conservé, pas de one-hot (aucune nominale)
Réglage	GridSearchCV, 5 plis stratifiés, par famille
Sélection	ROC-AUC, PR-AUC en arbitre
Déséquilibre	Pondération (comparée à l'autre)
Diagnostic	Écart train/validation, deux courbes
Seuil	Fixé après coup, rappel cible 75%
Interprétation	SHAP

13.2 Résultats

- Modèle retenu : **XGBoost**, ROC-AUC de 0,8503 et PR-AUC de 0,3712 sur le jeu de test.
- Le réglage était indispensable : sans GridSearch, le classement des familles était inversé.
- Le signal est presque entièrement additif — des arbres de profondeur 1 atteignent déjà l'essentiel de la performance.
- Le modèle retenu ne surapprend pas : l'écart entraînement-validation reste très faible.

13.3 Limites assumées

- **Associations transversales** : aucune causalité, aucune prédiction temporelle.
- **Données auto-déclarées** : biais de mémoire et de désirabilité sociale.
- **Part inexpliquée réelle** : 21 variables ne suffisent pas ; génétique, antécédents familiaux et environnement manquent.
- **Population américaine de 2015** : toute transposition demanderait une revalidation.
- **Traitement ordinal** : suppose des écarts constants entre modalités consécutives, approximation que les arbres atténuent.

Tous les chiffres de ce document proviennent de `resultats.json` et `metadata.json`, produits par l'exécution du notebook (graine fixe). Source des données : BRFSS, CDC, édition 2015 ; données publiques via Kaggle.