

Documentation technique

Entrepôt de données & Power BI

BRFSS Heart Analytics
Schéma en étoile DuckDB et restitution décisionnelle
à partir des données du Behavioral Risk Factor
Surveillance System (CDC, 2015)

Ahmed Ben Arfa

21/07/2026

github.com/AhmedBenArfa/BRFSS-Heart-Analytics

1. Introduction

Ce document décrit la couche décisionnelle du projet : la construction d'un entrepôt de données en schéma en étoile, puis sa restitution dans Power BI. Il fait suite à la documentation ETL & analyse exploratoire, qui a produit la table analytique sur laquelle repose l'entrepôt.

La couche décisionnelle répond à une question différente de celle de l'ETL. L'ETL demande « les données sont-elles justes ? » ; l'entrepôt et Power BI demandent « comment les organiser et les présenter pour les interroger efficacement ? ». Cette séparation des responsabilités structure l'ensemble du document.

Deux parties

Partie A — Entrepôt de données : modélisation dimensionnelle, construction du schéma en étoile sous DuckDB, contrôle d'intégrité.

Partie B — Power BI : connexion ODBC directe à l'entrepôt, mesures DAX, et les six pages du rapport décisionnel.

2. Partie A — Modélisation dimensionnelle

2.1 Pourquoi un schéma en étoile

Le schéma en étoile organise les données autour d'une table de faits centrale, entourée de tables de dimensions. La table de faits contient les mesures et des clés vers les dimensions ; chaque dimension porte les attributs descriptifs lisibles. Ce modèle est la référence pour l'analyse décisionnelle : il rend les requêtes simples et rapides, et il affiche des libellés compréhensibles plutôt que des codes numériques.

Le jeu de données source est une table plate et déjà encodée. La valeur ajoutée de l'entrepôt est double : reconstruire des dimensions lisibles à partir du codebook BRFS (afficher « 60-64 ans » et non « 9 »), et poser un modèle sur lequel Power BI se branche directement.

2.2 Grain et table de faits

Le grain de la table de faits est le niveau de détail d'une ligne. Ici, une ligne = un répondant à l'enquête. La source ne fournissant aucun identifiant, une clé technique `respondent_id` est générée (clé dégénérée).

Propriété	Valeur
Table de faits	<code>fact_respondent</code>
Grain	un répondant à l'enquête
Nombre de lignes	253 680
Colonnes	31
Clé dégénérée	<code>respondent_id</code>
Variable cible	<code>heart_disease</code>

La table de faits porte les clés étrangères vers les sept dimensions, les mesures continues (`bmi`, jours de mal-être), les indicateurs binaires de santé et de comportement, les variables dérivées de l'ETL, les drapeaux qualité, et la cible.

2.3 Les sept dimensions

Chaque dimension est reconstruite depuis le codebook BRFS. La clé de dimension est le code source lui-même : les codes BRFS étant déjà de petits entiers contigus, aucune clé de substitution artificielle n'est nécessaire — cela éviterait une jointure sans bénéfice.

Dimension	Attribut lisible	Membres
<code>dim_age</code>	<code>tranche_age</code>	13
<code>dim_education</code>	<code>niveau_education</code>	6
<code>dim_income</code>	<code>tranche_revenu</code>	8
<code>dim_sex</code>	<code>sexe</code>	2
<code>dim_genhlth</code>	<code>sante_generale</code>	5
<code>dim_diabetes</code>	<code>statut_diabete</code>	3
<code>dim_bmi_class</code>	<code>classe_imc</code>	6

2.4 Intégrité référentielle et membre « Inconnu »

Une bonne pratique consiste à prévoir un membre spécial « Inconnu » (clé -1) capable de capter tout code de fait absent du codebook, afin qu'aucune ligne ne devienne orpheline. Ce membre n'est toutefois ajouté que s'il est réellement nécessaire : si une dimension ne contient aucune valeur hors codebook ni valeur nulle, on ne crée pas de membre vide — cela éviterait de polluer les filtres de Power BI d'une modalité inutile.

Contrôle d'intégrité

Après construction : 0 clé étrangère orpheline sur les 7 dimensions. Les données étant propres (contrôles qualité de l'ETL), aucune dimension n'a reçu de membre « Inconnu ». Le schéma est cohérent.

2.5 Absence de dimension temporelle

Un schéma en étoile comporte fréquemment une dimension temps, mais elle n'est pas obligatoire : la modélisation dimensionnelle exige une table de faits et au moins une dimension, sans imposer d'axe temporel. Les données BRFSS 2015 sont transversales — un instantané, chaque répondant observé une seule fois. Une dimension temps y serait dégénérée (valeur unique) et sans apport analytique. Elle est donc volontairement absente ; le modèle privilégie les dimensions réellement discriminantes.

2.6 Diagramme du schéma

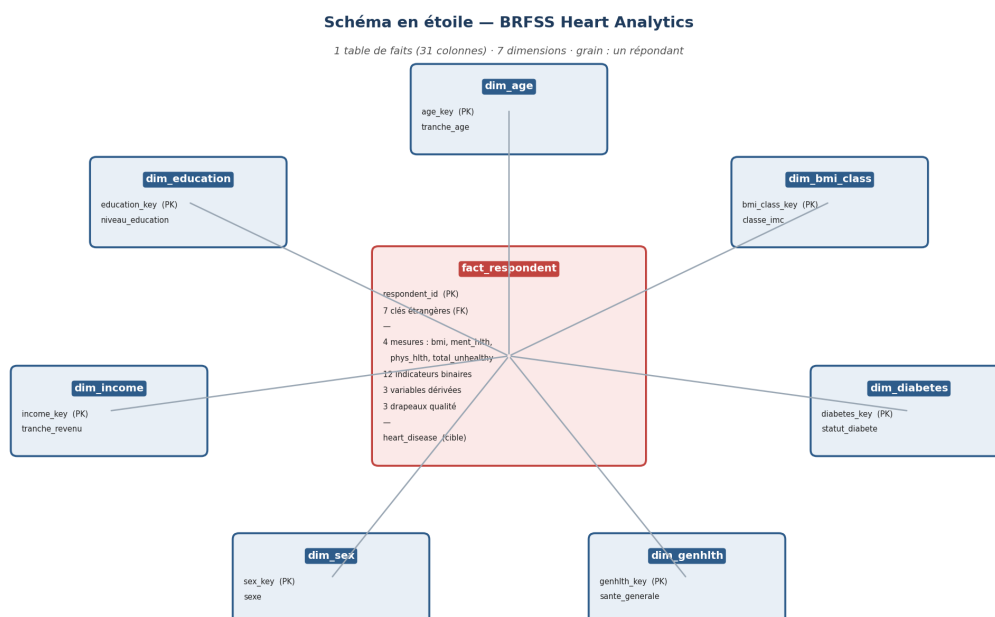


Schéma en étoile : fact_respondent au centre, sept dimensions du codebook

2.7 Construction et exports

Le script `build_star_schema.py` peuple les dimensions depuis le codebook, exécute le DDL qui construit la table de faits par jointure, vérifie l'intégrité, puis exporte chaque table en CSV et en Parquet (repli hors ligne). L'entrepôt DuckDB est un fichier unique, sans serveur à installer.

```
cd 02_data_warehouse
python build_star_schema.py          # construit le schéma + exports

python explore_warehouse.py          # tables + volumétrie
python explore_warehouse.py fact_respondent # aperçu
python explore_warehouse.py "SELECT AVG(heart_disease) FROM fact_respondent"
```

Verrou d'écriture DuckDB

DuckDB n'autorise qu'un seul processus en écriture, mais plusieurs lecteurs. Pour reconstruire l'entrepôt, fermer Power BI et tout noyau Jupyter connecté. Power BI se connecte en lecture seule, ce qui permet la coexistence de plusieurs lecteurs.


3. Partie B — Restitution Power BI

3.1 Connexion directe à l'entrepôt (ODBC)

Power BI se connecte directement à l'entrepôt DuckDB via une source de données ODBC, en lecture seule. Ce n'est pas un import de fichiers CSV isolés : le rapport interroge le modèle dimensionnel lui-même. Une DSN utilisateur nommée `heart_duckdb` pointe sur `heart.duckdb` avec `access_mode=read_only` ; les huit tables du schéma sont chargées, à l'exclusion de la table technique `analytical_base`.

Câblage automatique des relations

Grâce à un nommage cohérent des clés (`age_key` identique dans le fait et dans `dim_age`, etc.), Power BI détecte et crée les sept relations un-à-plusieurs automatiquement au chargement. Aucune relation n'est tracée à la main — la convention de nommage adoptée dans l'entrepôt paie directement ici.



Vue du modèle dans Power BI : les sept dimensions reliées à la table de faits

3.2 Mesures DAX

Les indicateurs sont calculés par des mesures DAX regroupées dans une table dédiée. La cible étant codée 0/1, sa moyenne donne directement le taux de maladie. Distinction clé : une mesure agrège et se place dans les valeurs ; une colonne calculée se calcule par ligne et sert d'axe ou de légende (ainsi la colonne Statut cardiaque, qui traduit 0/1 en libellés).

```
Taux Maladie Cardiaque =  
    DIVIDE ( SUM ( fact_respondent[heart_disease] ),  
            COUNTROWS ( fact_respondent ) )  
  
IMC Moyen = AVERAGE ( fact_respondent[bmi] )  
Facteurs Risque Moyens = AVERAGE ( fact_respondent[risk_factor_count] )  
Taux Hypertension = DIVIDE ( SUM ( fact_respondent[high_bp] ),  
                              COUNTROWS ( fact_respondent ) )  
  
Statut cardiaque = -- colonne calculée (pas une mesure)  
    IF ( fact_respondent[heart_disease] = 1, "Atteint", "Non atteint" )
```


La liste complète des mesures et colonnes figure dans `03_power_bi/mesures_dax.md`. Les axes catégoriels (tranche d'âge, revenu, études...) sont triés via « Trier par colonne » sur la clé numérique correspondante, faute de quoi Power BI trierait alphabétiquement.

3.3 Structure du rapport : six pages


Le rapport compte six pages, organisées du général au spécifique : deux pages descriptives (qui décrivent la population) et quatre pages analytiques (qui expliquent le risque).

Page	Type	Contenu principal
1 Vue d'ensemble	Analytique	KPI, risque par âge, répartition
2 Facteurs de risque	Analytique	Gradient des facteurs, courbe en J
3 Socio-démographique	Analytique	Revenu, études, âge × sexe
4 Santé & diabète	Analytique	Santé perçue, diabète, IMC
5 Profil population	Descriptive	Âge, sexe, revenu, IMC
6 Habitudes de vie	Descriptive	Tabac, activité, alimentation

3.4 Pages analytiques




Page 1 — Vue d'ensemble : indicateurs clés, risque par tranche d'âge, répartition atteints / non atteints



Page 2 — Facteurs de risque : le gradient de 1,2 % à 59 %, la courbe en J de l'IMC, l'hypertension par statut




Page 3 — Profil socio-démographique : gradient du revenu et des études, croisement âge × sexe




Page 4 — Santé perçue et diabète : deux facteurs majeurs, et le nuage IMC × risque par tranche d'âge

3.5 Pages descriptives

Ces deux pages décrivent la population étudiée indépendamment de la maladie — un rapport décisionnel complet ne se limite pas à la variable cible, il caractérise d'abord son échantillon.



Page 5 — Profil de la population : pyramide des âges, répartition par sexe et revenu, distribution de l'IMC



Page 6 — Habitudes de vie : taux de comportements de santé, état de santé perçu, jours de mal-être par âge

4. Synthèse

La couche décisionnelle transforme une table analytique plate en un modèle dimensionnel interrogeable, puis en un rapport lisible.

- Un schéma en étoile de 7 dimensions autour de fact_respondent (253 680 lignes) aux libellés issus du codebook.
- Une intégrité référentielle vérifiée (0 clé orpheline), sans membre « Inconnu » superflu.
- Une absence assumée de dimension temporelle, justifiée par la nature transversale des données.
- Une connexion Power BI directe à l'entrepôt en ODBC, avec câblage automatique des relations.
- Un rapport de six pages équilibré entre description de la population et analyse du risque.

Reproductibilité

Toutes les statistiques de ce document sont recalculées depuis l'entrepôt à la génération ; le diagramme et les captures proviennent des livrables réels. Régénérer : `cd 06_rapport && python _build_doc_pdf_dwh_powerbi.py`.

Source des données : Behavioral Risk Factor Surveillance System (BRFSS), Centers for Disease Control and Prevention, édition 2015. Données publiques diffusées via Kaggle.